
UrbanSafe AI

Ecosistema de Movilidad Predictiva y Segura

Deliverable 1 — Integrated Project Definition

Curso: Desarrollo de Productos de Datos (DS-3022) — UTEC

Ciclo: 2026-II | **Semana de entrega:** 07 (23 de septiembre de 2026)

Equipo: Elmer Jose Manuel Villegas Suarez | Alessandro Facundo Freed
Monzón Gallegos | Juan David Velo Poma (Líder)

Alcance: Definición del problema, requisitos, arquitectura, EDA, selección
de modelos y prototipo de baja fidelidad.

Índice

1. Resumen ejecutivo	2
2. Problema y propuesta de valor	2
2.1. Contexto y problemática	2
2.2. Propuesta de valor	2
2.3. Fuentes de datos	3
3. Data Product Canvas	3
3.1. Usuarios objetivo y stakeholders	4
4. Requerimientos y casos de uso	4
4.1. Historias de usuario y job stories	4
4.2. Casos de uso principales	4
4.2.1. UC-01 — Inferencia de aforo predictivo multiclase (núcleo)	4
4.2.2. UC-02 — Optimización prescriptiva de ruta peatonal segura	5
4.3. Requerimientos funcionales (RF)	5
4.4. Requerimientos no funcionales (RNF)	5
4.5. Criterios de aceptación (DoD)	6
5. Arquitectura del sistema	6
6. Workflow de la consulta principal	7
6.1. Flujo petición – respuesta	8
7. Análisis exploratorio de datos (EDA)	9
7.1. Panorama del dataset	9
7.2. Principales hallazgos	9
8. Selección y evaluación de modelos	10
8.1. Pronóstico de validaciones (base de los módulos)	10
8.2. Módulo 1 — Estimador continuo del tiempo de espera (ETA)	11
8.3. Módulo 2 — Predictor multiclase de aforo	11
8.4. Módulo 3 — Motor prescriptivo de recomendación	12
8.5. Módulo 4 — Detector de anomalías espacio-temporales	12
9. Prototipo de baja fidelidad	12
10. Datasets, diccionarios y pipeline de datos	13
10.1. Flujo general del pipeline	13
10.2. Diccionarios de datos	14
10.3. Claves de unión y trazabilidad	14
11. Cronograma y próximos pasos	15
11.1. Próximos pasos técnicos (Fase 2, S08–S10)	16
12. Referencias	16
12.1. Documentación interna del repositorio	16

1 Resumen ejecutivo

UrbanSafe AI es un producto de datos orientado al Sistema Integrado de Transporte de Lima Metropolitana (Metropolitano y Corredores Complementarios). Su objetivo central es **reducir los tiempos de espera y la incertidumbre de los pasajeros** en estaciones y paraderos, mostrando el **aforo proyectado** de las próximas unidades y su **tiempo estimado de llegada (ETA)**, y recomendando de forma prescriptiva si el usuario debe **abordar, esperar la siguiente unidad o cambiar de paradero**. Como funcionalidad secundaria, incorpora un módulo de **enrutamiento peatonal seguro** (primera y última milla) que prioriza vías iluminadas y vigiladas sobre la distancia más corta.

El proyecto evoluciona de la *Hackathon ATU 2026* y del concepto *Urbyte*. Combina fuentes de datos abiertos (validaciones de transporte, telemetría de tráfico, OpenStreetMap y clima) con una capa sintética de congestión y aforo para resolver el problema de arranque en frío.

Estado del avance (S07). Este entregable consolida la **Fase 1 — Definición e Integración de Requerimientos**: especificación de requisitos funcionales y no funcionales, casos de uso, análisis exploratorio de datos (EDA), selección justificada de modelos y prototipo de baja fidelidad. La demanda base prevista es la de la **ATU de Lima** (solicitada y pendiente de respuesta); como proxy de la misma naturaleza BRT se usa el dataset de **Validaciones Troncales de TransMilenio (Bogotá)**.

2 Problema y propuesta de valor

2.1 Contexto y problemática

En el Sistema Integrado de Transporte de Lima los usuarios enfrentan alta incertidumbre respecto a los **tiempos de llegada** y al **nivel de aforo** (asientos disponibles, de pie o bus saturado) de las unidades, lo que genera tiempos de espera ineficientes, viajes incómodos y aglomeraciones severas en paraderos.

A esta ineficiencia se suma la problemática de seguridad ciudadana en la *primera y última milla* (tramos a pie desde el origen hacia el paradero y desde la estación hacia el destino). Según el INEI (2025), la percepción de inseguridad en las principales áreas urbanas supera el 85 %, con mayor incidencia de robos y hurtos en vías desoladas o mal iluminadas. Las herramientas de navegación convencionales optimizan por distancia o tiempo mínimo, ignorando el riesgo peatonal y el estado de ocupación de las unidades.

2.2 Propuesta de valor

- **Predictiva:** inferencia del aforo futuro de las unidades (*Asientos / De pie / Saturado*) y del ETA de las dos próximas unidades, reduciendo la permanencia en el andén.
- **Prescriptiva:** matriz de decisión que recomienda abordar, esperar el siguiente servicio o cambiar de paradero, con nivel de confianza y banda de incertidumbre.
- **Seguridad peatonal:** enrutamiento por índice de riesgo urbano para la primera y última milla, con comparación contra la ruta más corta y tolerancia de caminata ajustable.

2.3 Fuentes de datos

Cuadro 1: Fuentes de datos del producto.

Fuente	Rol en el producto
Validaciones ATU (ProTransporte)	Demanda base prevista — <i>solicitud pendiente</i> . Mientras tanto se usa como proxy el dataset de Validaciones Troncales de TransMilenio (Bogotá), misma naturaleza BRT.
TomTom Traffic API	Telemetría de congestión en tiempo real (key TOMTOM_KEY en <code>.env</code>); feature de retraso del bus. Sin key, el sistema opera en <i>Modo Histórico</i> (RF-05).
OpenStreetMap (OSM)	Infraestructura urbana (luminarias, comisarías, comercios, red vial) → índice de seguridad peatonal (segundo plus).
Meteostat	Clima horario de Bogotá — solo EDA ; no entra a los predictores.
Dataset sintético	Capa de congestión (<code>congestion_sintetica.csv</code>) y simulación de aforo para el arranque en frío.

3 Data Product Canvas

El lienzo del producto de datos define la propuesta de valor, los clientes y usuarios, las fuentes de datos, las decisiones soportadas y el modelo de negocio del producto.



Figura 1: Lienzo del Producto de Datos (imagen integrada de la entrega).

3.1 Usuarios objetivo y stakeholders

Usuarios del transporte público (pasajeros y peatones): planifican sus viajes reduciendo la incertidumbre del aforo, optimizando sus tiempos de espera y transitando por caminos peatonales con menor exposición a la delincuencia.

Planificadores urbanos y entidades reguladoras (ATU y municipios): aprovechan el análisis agregado de la demanda e identifican zonas críticas de la primera y última milla.

Cuadro 2: Mapa de stakeholders y actores.

Stakeholder / Actor	Categoría	Impacto / Poder
Pasajeros y peatones urbanos	Actor primario	Alto / Alto
Familiares y red de apoyo	Beneficiario indirecto	Medio / Bajo
Autoridad de Transporte Urbano (ATU)	Aliado estratégico	Alto / Medio
Municipalidades distritales / Serenazgo	Stakeholder operativo	Medio / Medio
Conductores y operadores de bus	Stakeholder indirecto	Medio / Bajo

4 Requerimientos y casos de uso

4.1 Historias de usuario y job stories

- **US-01 (Núcleo):** como pasajero en hora punta, quiero consultar la categoría de ocupación proyectada del próximo bus antes de que llegue, para decidir si me preparo para subir, espero la siguiente unidad o camino a otro paradero.
- **US-02:** como usuario en el andén, quiero comparar el tiempo de llegada y el aforo del bus actual frente al siguiente, para elegir la alternativa más cómoda y rápida.
- **US-03:** como usuario que acaba de abordar, quiero confirmar con un toque si la estimación de aforo fue acertada (retroalimentación del modelo).
- **US-04 (Segundo plus):** como peatón, quiero una ruta guiada por calles iluminadas y transitadas para reducir mi exposición a zonas con riesgo delictivo.

4.2 Casos de uso principales

4.2.1 UC-01 — Inferencia de aforo predictivo multiclase (núcleo)

Actores: Pasajero/peatón (principal); APIs y modelo ML (secundarios).

Disparador: el usuario selecciona servicio, ruta y estación de abordaje.

Flujo principal: (1) se ingiere velocidad y congestión de TomTom Traffic; (2) se cruza con el histórico horario de validaciones; (3) el modelo clasifica el aforo en *Asientos disponibles / De pie / Saturado*; (4) la interfaz muestra el aforo, su intervalo de confianza y el ETA.

Flujo alternativo: si TomTom supera el timeout (2 s), el backend conmuta a inferencia basada en el histórico (respuesta con banner de *Modo Histórico*).

4.2.2 UC-02 — Optimización prescriptiva de ruta peatonal segura

Se carga el subgrafo peatonal OSM, se asigna a cada tramo un costo ponderado $\text{Costo} = \text{Distancia} \times \text{Penalización}(\text{FaltaLuz}, \text{FaltaComercios}, \text{DistanciaComisaria})$ y se calcula la trayectoria de costo mínimo con Dijkstra/A*: la app presenta la ruta segura frente a la ruta geométrica más corta.

4.3 Requerimientos funcionales (RF)

Cuadro 3: Requerimientos funcionales.

ID	Módulo	Descripción
RF-01	Núcleo	Mostrar el nivel de ocupación esperado de la próxima unidad en tres estados: Asientos disponibles / viaje de pie / saturado.
RF-02	Núcleo	Calcular el tiempo estimado de espera (min) de las dos próximas unidades.
RF-03	Núcleo	Indicar si la opción más eficiente es abordar, esperar la siguiente o cambiar de paradero.
RF-04	Núcleo	Feedback de un solo toque para confirmar la estimación al abordar.
RF-05	Núcleo	Modo resiliente: ante caída de la API (TomTom), degradar a la matriz histórica de la ATU.
RF-06	Peatonal	Computar un score de riesgo por tramo vial (alumbrado, comisarías, comercios, paraderos).
RF-07	Peatonal	Generar la ruta peatonal prescriptiva y compararla con la ruta más corta geométrica.
RF-08	Peatonal	Selector de tolerancia a caminata adicional para mayor seguridad.

4.4 Requerimientos no funcionales (RNF)

Cuadro 4: Requerimientos no funcionales.

ID	Ámbito	Descripción
RNF-01	Precisión analítica	$\text{Accuracy} \geq 75\%$ y $\text{F1-macro} \geq 0,72$ en prueba.
RNF-02	Latencia global	Consulta de aforo y rutas en $\leq 2,0$ s en el percentil 95 (4G/5G).
RNF-03	Disponibilidad	$\geq 99,0\%$ dentro del horario operativo (05:00–23:30).
RNF-04	Ergonomía móvil	Operación con una sola mano, paleta de alto contraste nocturno, ≤ 2 toques para el resultado.
RNF-05	Gobernanza y privacidad	Sin geolocalización continua ni datos identificables; coordenadas de consulta efímeras (Ley N.º 29733).

4.5 Criterios de aceptación (DoD)

Cuadro 5: Criterios de aceptación.


ID	Requiere	Criterio
AC-01	Pipeline	Integración automatizada de ATU, TomTom y OSM sin quiebre de esquema.
AC-02	Aforo	Clasificador multiclase con $F1 \geq 0,72$ en las tres categorías (test independiente).
AC-03	Espera	Recomendar abordar/esperar/cambiar con exactitud $\geq 80\%$ en casos evaluados.
AC-04	Respuesta	Consulta integral en $\leq 2,0$ s (P95).
AC-05	Grafo peatonal	Rutas con menor score de riesgo que la más corta en $\geq 80\%$ de casos.
AC-06	Usabilidad	$\geq 60\%$ de usuarios declaran menor tiempo de espera percibido.

5 Arquitectura del sistema

El diagrama de arquitectura del sistema (Figura 2) define los componentes previstos: ingesta de datos externos, capa de almacenamiento, pipeline de preprocesamiento, los modelos de cada módulo y la interfaz de usuario.

UrbanSafe AI — AWS Architecture

Ecosistema de Movilidad Predictiva



eraser

Figura 2: Diagrama de arquitectura del sistema UrbanSafe AI.

- **Capa de datos:** fuentes Open Data (TransMilenio/ATU, TomTom, OSM, Meteostat) y dataset sintético de congestión.
- **Capa de procesamiento:** scripts de descarga idempotentes y notebooks EDA que producen el dataset limpio de modelado.
- **Capa analítica:** cascada de inferencia (Chronos → ETA → Aforo → Recomendación) más detector de anomalías.
- **Capa de producto:** API REST (FastAPI) y app móvil con estados de degradación.

6 Workflow de la consulta principal

La Figura 3 ilustra el flujo de la consulta principal: desde la selección del usuario hasta la respuesta del sistema.




Figura 3: Workflow de la consulta principal (aforo + ETA + recomendación).

6.1 Flujo petición – respuesta

- Usuario (app móvil, 2 toques):** selecciona servicio (Metropolitano / Corredor), ruta y estación de abordaje. Declaración de uso efímero de ubicación (RNF-05).
- Petición HTTP** a la API REST: `/consulta {servicio, ruta, estacion, hora}`.
- Cascada de inferencia** (presupuesto $P95 \leq 2$ s):
 - Pronóstico:** Chronos-Bolt-Small (fundacional, zero-tuning, CPU) pronostica las validaciones de la estación con banda de incertidumbre q10–q90.
 - Módulo 1 — ETA:** blend $C = w \cdot (\text{Chronos}) + (1 - w) \cdot (\text{histórico por estación/hora})$, ajustado $\times 1.1$ (ocupación media) o $\times 1.3$ (alta); ETA de las 2 próximas unidades.
 - Módulo 2 — Aforo:** HistGB clasifica en Asientos / De pie / Saturado usando features de calendario, identidad de estación y validaciones pronosticadas.

- d) *Módulo 4 — Anomalías*: Isolation Forest vigila el corredor (drift) sin bloquear la respuesta.
- e) *Módulo 3 — Recomendación*: Tree aplica la matriz $U(\text{ETA}, \text{Aforo})$:
- $\text{ETA} \geq 10 \text{ min} \rightarrow \text{cambiar de paradero}$;
 - $\text{ETA} < 10 \text{ min}$ y bus saturado $\rightarrow \text{esperar siguiente}$ si el siguiente no viene saturado; si también viene lleno $\rightarrow \text{cambiar de paradero}$;
 - en otro caso $\rightarrow \text{abordar ahora}$.
4. **Fallback (Modo Histórico, RF-05)**: si la telemetría externa supera el timeout o no hay API key, la estimación se degrada a la matriz histórica de validaciones/headway, con banner informativo en la respuesta.
5. **Respuesta JSON**: aforo con confianza e intervalo, ETA de las 2 unidades (rango, p. ej. 3–5 min y 9–12 min), recomendación y banner de Modo Histórico si aplica.
6. **Feedback (RF-04)**: el usuario toca “Ya abordé este bus” y marca la categoría real; el dato se persiste como ground-truth para reentrenamiento.

7 Análisis exploratorio de datos (EDA)

7.1 Panorama del dataset

Cuadro 6: Vista global del dataset (62 días, julio–agosto 2026).

Métrica	Valor
Filas del dataset limpio	$176,783 \times 28$
Validaciones totales	88,884,983
Estaciones	153 códigos Tullave (156 nombres)
Días / troncales / líneas	62 / 12 / 13
<i>Día 1</i> (hábil) vs <i>Día 2</i> (domingo/festivo)	94 % / 6 %
Demanda en franjas pico	62 % (pico AM 32.5 % + pico PM 29.2 %)
Estaciones sobre capacidad en su hora pico	133 de 153 (>100 %)

7.2 Principales hallazgos

1. **Estacionalidad fuerte**: ‘DiaSemana’, ‘Es_Habil’ y ‘Hora’ explican la mayor parte de la varianza; la hora es la dimensión más predictiva.
2. **Doble pico** (AM 05–09 h, PM 16–21 h) con forma distinta en domingo (un solo pico vespertino): se particiona por ‘Franja’ y ‘Tipo_Dia_ok’.
3. **Festivos mal etiquetados** en la fuente (4 festivos como *Día 1*): se corrigen con ‘Es_Festivo’ y ‘Tipo_Dia_ok’; los splits temporales aíslan días singulares.
4. **La oferta sigue a la demanda** (corr. Frecuencia–Validaciones = 0.498); ‘Frecuencia’ y ‘N_Rutas’ correlacionan 0.92 (multicolinealidad a vigilar).
5. **Ocupación proxy**: ‘Ocupacion_pk = Validaciones / Cap_total’ (corr. 0.94 con ‘Validaciones’), base de la etiqueta de aforo.

6. **Saturación generalizada:** 133/153 estaciones superan el 100 % de capacidad en su hora más cargada.
7. **El clima es despreciable:** lluvia ligera asociada a -3% (dentro del ruido), todas las correlaciones $|r| \leq 0,10$ a igual franja; la señal de temperatura es un proxy del ciclo horario. **El clima queda excluido del feature store.**
8. **Cobertura incompleta:** 5 % de filas sin oferta GTFS (flag ‘Sin_Oferta’) y 7.5 % sin capacidad (‘sin_capacidad’); no se imputa.
9. **Entorno urbano (OSM):** los POIs se dominan por comercio/negocio (96.4 %); las features de seguridad (luminaria, comisaria) son escasas e independientes de la actividad comercial (corr. $\approx -0,04$ / 0.24).




Figura 4: Serie temporal diaria de validaciones.




Figura 5: Heatmap hora $\times$ día de la semana.




Figura 6: Top 15 estaciones por ocupación en hora pico.




Figura 7: Matriz de correlación (Pearson).

8 Selección y evaluación de modelos

8.1 Pronóstico de validaciones (base de los módulos)

Se compara **Chronos-Bolt-Small** (modelo fundacional de series, zero-shot, descargado de Hugging Face; tokens numéricos sobre un encoder-decoder estilo T5, entrega pronósticos probabilísticos con banda q10–q90) contra baselines clásicos mediante *walk-forward* de 5 días sobre el grid $1,488 \text{ h} \times 156 \text{ estaciones}$.

Cuadro 7: Métricas globales del pronóstico (promedio walk-forward 5 días).

Modelo	MAE	RMSE	WMAPE
Chronos (seleccionado)	56.32	147.32	0.165
Naive_24 (baseline)	104.12	244.92	0.237

Justificación de Chronos. Cero riesgo de sobreajuste (62 días por estación), manejo de series dispersas con ausencias (rellenadas con ceros), cero esfuerzo de despliegue (sin checkpoints propios), baja latencia en CPU y banda probabilística calibrada auditable frente a ‘naive_24’ ($\approx 46\%$ menos MAE y $\approx 40\%$ menos RMSE).

8.2 Módulo 1 — Estimador continuo del tiempo de espera (ETA)

Cuatro opciones evaluadas en walk-forward: **A** (‘A_chronos’) pronóstico puro de headway con Chronos; **B** (‘B_hist’) tabla histórica ajustada por ocupación ($\times 1.1/\times 1.3$); **C** (‘C_blend’) blend $w \cdot A + (1 - w) \cdot B$ con peso seleccionado sin fuga; **D** (‘D_ratio’) ablación multiplicando por el ratio de congestión sintético.

Cuadro 8: Comparativa del Módulo 1 (ETA) por opción.

Opción	MAE (min)	RMSE (min)
C_blend (seleccionado)	0.2426	1.0854
A_chronos	0.2451	1.2972
B_hist	0.2968	0.8859
D_ratio	0.4128	1.1314

Lectura. El blend **C** gana en MAE. La ablación **D** (ratio de congestión sintético) **empeora** el MAE a 0.413: el ajuste por congestión solo se justifica con telemetría **real** (TomTom Traffic) y queda **desactivado** en esta iteración. En producción (S08) se recalibraría: $\text{eta_efectivo} = \text{eta_base} \times \text{ratio}$.

8.3 Módulo 2 — Predictor multiclase de aforo

La ocupación real se discretiza en tres clases con cuantiles calibrados en **train** ($l_o = Q_{60} = 1,479$; $h_i = Q_{90} = 9,013$). Features: ciclo horario, ‘dia’, ‘Es_Habil’ y ‘Estacion_cod’. Ocho clasificadores comparados:

Cuadro 9: Comparativa de clasificadores de aforo (Módulo 2).

Modelo	accuracy	bal. acc	F1 macro	ROC-AUC ovr
HistGB (seleccionado)	0.9447	0.9336	0.9408	0.9852
LightGBM	0.9422	0.9296	0.9373	0.9847
XGBoost	0.9422	0.9288	0.9372	0.9856
Random Forest	0.9159	0.8813	0.9014	0.9789
Logistic (baseline)	0.8120	0.6324	0.6550	0.8851

Resultado en test (14,178 casos): accuracy **0.945**; F1 — Asientos 0.961, De pie 0.904, Saturado 0.957. El *nowcasting* honesto (misma etiqueta, ocupación real en test) alcanza F1 Saturado 0.876, lo que cuantifica la pérdida esperada al pasar de ocupación real a pronosticada.

8.4 Módulo 3 — Motor prescriptivo de recomendación

Matriz U (ETA, Aforo) con umbral recalibrado a 10 min y chequeo de la siguiente unidad. Se mide la **fidelidad de preservación de la regla** ($AC-03 \geq 0,80$) y los falsos positivos de ‘Abordar’ (error de mayor costo).

Cuadro 10: Comparativa del Módulo 3 (recomendación) sobre el test (12,358 decisiones).

Modelo	Fidelidad AC-03	F1 macro	FP Abordar
Tree (seleccionado)	0.9997	0.9977	0.0000
Random Forest	0.9997	0.9977	0.0000
Gradient Boosting	0.9997	0.9977	0.0000
HistGB	0.9992	0.9817	0.0005
XGBoost	0.9987	0.9611	0.0006

8.5 Módulo 4 — Detector de anomalías espacio-temporales

Isolation Forest (contamination 0.05) entrenado solo sobre el contexto $\leq$ split y aplicado al test. Umbrales por percentiles: p0.5 −0,686, p3.0 −0,605. El día más anómalo del test es 2026-08-31 (fracción de outliers 0.095), consistente con el cierre de señal del periodo.

9 Prototipo de baja fidelidad

El flujo de navegación del núcleo requiere **2 toques** ($P1 \rightarrow P2$), conforme al RNF-04. Pantallas principales: selección de servicio/ruta/estación, resultado de aforo (con modo nocturno automático 18:00–06:00), feedback de un toque y ruta peatonal segura.



Figura 8: Resultado de aforo predictivo (RF-01/02/03).



Figura 9: Ruta peatonal segura (RF-06/07/08).

Trazabilidad requerimiento → pantalla.

- RF-01/02/03 y RF-05 → pantalla de resultado de aforo (banner de Modo Histórico).
- RF-04 → pantalla de validación con tres botones de categoría real.
- RF-06/07/08 → pantalla de ruta peatonal segura (desglose de riesgo, comparativa y slider de tolerancia 0–15 min).
- RNF-02/04/05 → estados de carga, tema oscuro y avisos de procesamiento efímero.

10 Datasets, diccionarios y pipeline de datos

10.1 Flujo general del pipeline

```
data cruda (TransMilenio / Clima / OSM)                deliveries/week07/data/
| process_transmilenio.py . download_*.py
```

```

v
dataset_base.csv (177,944 x 17)                                data/transmilenio/dataset.csv
| code/eda/eda_transmilenio.ipynb (limpieza + FE)
v
dataset_limpio.csv (176,783 x 28)                                data_processed/    <- base de modelado
| code/eda/eda_OSM.ipynb
+--> dataset_osm_estaciones_limpio.csv (156 x 12)
| code/scripts/congestion.py (S08: TomTom real)
+--> congestion_sintetica.csv (232,128 x 7)
| code/model/Modelamiento_Preeliminar.ipynb
+--> pronostico_24h_estaciones.csv (3,480 x 12)
+--> eval_walkforward_modelos.csv (55 x 5)
+--> metricas_modelos.csv (2 x 4)
+--> code/model/outputs/    (comparativas M1/M2/M3)

```

10.2 Diccionarios de datos

Los diccionarios completos se encuentran en docs/data_dictionary:

- Fuentes crudas: Data_Dictionary_Transmilenio.md, Data_Dictionary_Clima.md, Data_Dictionary_OS
- Procesados y salidas: Data_Dictionary_Procesados.md, DatasetDescriptions.md.

10.3 Claves de unión y trazabilidad

Cuadro 11: Relaciones y claves de unión entre datasets.

Desde	Hacia	Clave
dataset_limpio	dataset_osm_estaciones_limpio	num_est
dataset_limpio	clima_hora_*.csv	(Fecha, Hora)
congestion_sintetica	pronóstico / ETA	(Estacion, Fecha_Hora)
pronostico_24h_estaciones	contexto histórico	(Estacion, Hora_n)

Privacidad. Ningún dataset procesado contiene PII; el número de tarjeta (crudo) es un hash SHA-256 y no se persiste en data_processed. La semilla sintética es fija (42) para reproducibilidad byte a byte.

11 Cronograma y próximos pasos

Cuadro 12: Cronograma de entregables del curso (fases S07–S15).

Semana	Entregable	Responsable principal
S07	Integrated Project Definition (requerimientos, EDA, selección de modelos, datasets)	Elmer (datos), Juan David (modelo), Alessandro (requerimientos/archivos)
S08	Examen parcial (sin entrega): ajustar TomTom real y calibrar modelos	Elmer (ingesta), Juan David (modelos)
S09	Prototipo base: API REST, pipeline en vivo, Módulos 3 y 4	Alessandro (backend), Elmer (pipeline)
S10	Prototipo funcional (frontend, persistencia, métricas vs baselines)	Alessandro (frontend), Juan David (validación)
S11	Eje 2: Módulo peatonal (grafo OSM + costo por riesgo)	Elmer

11.1 Próximos pasos técnicos (Fase 2, S08–S10)

- Integrar **TomTom Traffic** real y recalibrar sin reentrenar: $\text{eta_efectivo} = \text{eta_base} \times \text{ratio}$ (desactiva la ablación D sintética).
- Serializar los artefactos ML (Chronos zero-shot, HistGB, Tree) y diseñar el esquema OpenAPI/Swagger del backend FastAPI.
- Implementar la cascade de inferencia con latencia $P95 \leq 2$ s y el modo resiliente RF-05.
- Persistencia (PostgreSQL/DuckDB) y primer frontend funcional.
- Validar el módulo peatonal (grafo OSM, índice de riesgo) en S11.

12 Referencias

- INEI (2025). *Percepción de la Inseguridad Ciudadana y Victimización en Áreas Urbanas de Lima Metropolitana*. <https://www.inei.gob.pe/estadisticas/indice-tematico/seguridad-ciudadana>
- ATU (2026). *Hackathon 2026*. <https://www.gob.pe/institucion/atu/noticias/atu-lanza-la-hackathon>
- ProTransporte & ATU. *Portal de Datos Abiertos del Sistema Integrado de Transporte*. <https://sistemas.protransporte.gob.pe/DatosAbiertos/>
- TransMilenio (Bogotá). *Datos abiertos del operador*. <https://www.transmilenio.gov.co/datosAbiertos/>
- TomTom Traffic API. <https://docs.tomtom.com/traffic-api/>
- Amazon Science. *Chronos-Bolt (pronóstico de series)*. <https://github.com/amazon-science/chronos-forecasting>

12.1 Documentación interna del repositorio

- `deliveries/week07/docs/Requirements.md` — especificación de requerimientos (RF/RNF, AC).
- `deliveries/week07/docs/DataAnalysis.md` — EDA (fuentes, preprocesamiento, hallazgos).
- `deliveries/week07/docs/ModelSelection.md` — selección/justificación de modelos y resultados.
- `deliveries/week07/docs/Wireframes.md` — wireframes de baja fidelidad.
- `deliveries/week07/docs/data_dictionary/` — diccionarios de datos (crudos y procesados).
- `deliveries/week07/code/download/Guia.md` — guía técnica de descarga/ingesta.